

SciGYM における反復上限の引き上げと LARGE SPLIT の事前登録評価: OPEN-WEIGHT 5 モデルは反復を 100 に増やすと改善し、より大きな系でも論文の最良に届くか

Anonymous authors

Paper under double-blind review

ABSTRACT

SciGym (Duan et al., 2025) は、反応をすべて取り除いた SBML モデルを LLM エージェントに渡し、摂動実験とコード実行を繰り返して反応機構を復元させるベンチマークである。論文は反復上限 20 で SciGym-small 137 件だけを評価しており、反復を増やしたときに性能が飽和するのか、より大きな系 (large split 213 件) でどこまで解けるのかは示されていない。本研究は、公開コードの Controller と評価器をそのまま使い、理研の計算機 RIKYU の推論 API で提供される open-weight 5 モデル (kimi-k2.6, kimi-k3, deepseek-v4.1-flash, qwen3.8-27b, qwen3.6-35b) を、反復上限 100 で small と large の両方に走らせる。実験前に、(1) small では各モデルの平均 Simulation Trajectory Error (STE) が先行研究の 20 反復の値以下になること、(2) large では各モデルの平均 STE が論文 Table 1 の最良行 (Gemini-2.5-Pro の 0.3212) 以下になること、を反証線として登録する。反復上限は当初 200 を検討したが、5 モデル共通の文脈長 262144 トークンと計算機の 1 job 4 日の上限から 100 に下げた。提出までに使った反復数、上限前に自ら提出した件数、文脈超過で提出に至らなかった件数を飽和の指標として表で報告する。本版 (2026 年 9 月 29 日) は中間報告で、10 run はいずれも実行中のため主張の判定はすべて保留であり、執筆時点の実行状況と、実行中に加えた打ち切り・呼び直し・圧縮の規則を記す。

1 はじめに

LLM に科学的発見のサイクル全体 (実験の設計、結果の解析、機構の提案) を行わせて測るベンチマークとして、SciGym (Duan et al., 2025) が提案された。BioModels 由来の SBML モデルから反応をすべて取り除いたものをエージェントに渡し、エージェントは初期濃度を変えた摂動実験を要求し、返ってきた時系列を Python で解析し、最終的な SBML を提出する。提出は任意の時点で行え、反復数の上限は 20 である (Duan et al., 2025, s1.p3)。論文は計算資源の制約から SciGym-small の 137 件だけを評価した (Duan et al., 2025, s1.p2)。

先行する AIRAS の研究は、同じ Controller と反復上限 20 で open-weight 6 モデルの平均 STE が論文の GPT-4.1-mini の 0.6007 を 0.05 より大きくは上回らないかを評価し (auto-res2/scigym-rikyu-open-models , AIRAS, s3.p1)、kimi-k2.6 が 0.2100 (auto-res2/scigym-rikyu-open-models , AIRAS, s3.p2)、kimi-k3 が 0.2251 (auto-res2/scigym-rikyu-open-models , AIRAS, s3.p3)、deepseek-v4.1-flash が 0.2405 (auto-res2/scigym-rikyu-open-models , AIRAS, s3.p4)、qwen3.8-27b が 0.2479 (auto-res2/scigym-rikyu-open-models , AIRAS, s3.p5)、qwen3.6-35b が 0.4571 (auto-res2/scigym-rikyu-open-models , AIRAS, s3.p6) であった。その実行では 137 件のうちおよそ 8 割の件が上限の 20 反復を使い切っており、反復を増やせばさらに良くなるのか、それとも飽和しているのかは分からない。また large split の 213 件は論文でも先行研究でも評価されていない。

本研究はこの 2 点を、同じ 5 モデル、同じ Controller、反復上限 100 で問う。判定は AIRAS の事前登録の枠組みに従い、仮説・判定基準・予測区間・実行条件を実験前に記録・凍結し、実験後は計測値だけを流し込む。

2 関連研究

SciGym (Duan et al., 2025) の評価指標は 3 つで、種間の相互作用の F1 (NTS)、反応物と生成物の集合が一致した反応の適合率・再現率・F1 (RMS. modifier まで要求する厳格版もある) (Duan et al., 2025, s1.p7)、および全種の時系列の対称平均絶対パーセント誤差 (STE) (Duan et al., 2025, s1.p8) である。論文 Table 1 では Gemini-Pro が最良で (Duan et al., 2025, s1.p6)、その STE は 0.3212 である (Duan et al., 2025, s1.p5)。

3 仮説と予測

以下は記録 (record.json) から生成された仮説・主張・判定基準・予測区間の一覧である。実験後は Observed と Verdict が計測値から埋められる。

Hypothesis 1. RIKYU の推論 API の open-weight モデル 5 種 (kimi-k2.6, kimi-k3, deepseek-v4.1-flash, qwen3.8-27b, qwen3.6-35b) は、SciGym 公開コードの Controller で反復上限を論文の 20 から 100 に引き上げて SciGym-small 137 件を解かせたとき、いずれも平均 Simulation Trajectory Error (STE) が先行研究の 20 反復の値以下になる (反復を増やしても悪化しない)。(Duan et al., 2025, s1.p3), (auto-res2/scigym-rikyu-open-models , AIRAS, s3.p1, s3.p2, s3.p3, s3.p4, s3.p5, s3.p6)

- Claim 1** kimi-k2.6 で SciGym-small 137 件を最大 100 反復で解かせたときの平均 STE は、先行研究の 20 反復の値 0.2100 以下である。 (Duan et al., 2025, s1.p3, s1.p4), (auto-res2/scigym-rikyu-open-models , AIRAS, s3.p2, s3.p7), (h4duan, 2025, s2.p1) *Rationale:* 反復を 5 倍にしても悪化しないことが示せれば、h1 の kimi-k2.6 の部分を担う。 *Criterion:* `kimi-k2.6-small.trajectory_smape` $- 0.21005 \leq 0$. *Prediction:* $[-0.08, 0.02]$ (20 反復では大半の件が上限まで使い切っていたので余地はあるが、文脈が長くなると推論が乱れることもある。改善は小さめと見る)。 *Observed:* pending. *Verdict:* pending.
- Claim 2** kimi-k3 で SciGym-small 137 件を最大 100 反復で解かせたときの平均 STE は、先行研究の 20 反復の値 0.2251 以下である。 (Duan et al., 2025, s1.p3, s1.p4), (auto-res2/scigym-rikyu-open-models , AIRAS, s3.p3, s3.p7), (h4duan, 2025, s2.p1) *Rationale:* c1 と同じ。h1 の kimi-k3 の部分を担う。 *Criterion:* `kimi-k3-small.trajectory_smape` $- 0.225072 \leq 0$. *Prediction:* $[-0.08, 0.02]$ (c1 と同じ)。 *Observed:* pending. *Verdict:* pending.
- Claim 3** deepseek-v4.1-flash で SciGym-small 137 件を最大 100 反復で解かせたときの平均 STE は、先行研究の 20 反復の値 0.2405 以下である。 (Duan et al., 2025, s1.p3, s1.p4), (auto-res2/scigym-rikyu-open-models , AIRAS, s3.p4, s3.p7), (h4duan, 2025, s2.p1) *Rationale:* c1 と同じ。h1 の deepseek-v4.1-flash の部分を担う。 *Criterion:* `deepseek-v4.1-flash-small.trajectory_smape` $- 0.24046 \leq 0$. *Prediction:* $[-0.08, 0.02]$ (c1 と同じ)。 *Observed:* pending. *Verdict:* pending.
- Claim 4** qwen3.8-27b で SciGym-small 137 件を最大 100 反復で解かせたときの平均 STE は、先行研究の 20 反復の値 0.2479 以下である。 (Duan et al., 2025, s1.p3, s1.p4), (auto-res2/scigym-rikyu-open-models , AIRAS, s3.p5, s3.p7), (h4duan, 2025, s2.p1) *Rationale:* c1 と同じ。h1 の qwen3.8-27b の部分を担う。 *Criterion:* `qwen3.8-27b-small.trajectory_smape` $- 0.247934 \leq 0$. *Prediction:* $[-0.08, 0.02]$ (c1 と同じ)。 *Observed:* pending. *Verdict:* pending.
- Claim 5** qwen3.6-35b で SciGym-small 137 件を最大 100 反復で解かせたときの平均 STE は、先行研究の 20 反復の値 0.4571 以下である。 (Duan et al., 2025, s1.p3, s1.p4), (auto-res2/scigym-rikyu-open-models , AIRAS, s3.p6, s3.p7), (h4duan, 2025, s2.p1) *Rationale:* c1 と同じ。h1 の qwen3.6-35b の部分を担う。 *Criterion:* `qwen3.6-35b-small.trajectory_smape` $- 0.457089 \leq 0$. *Prediction:* $[-0.15, 0.02]$ (20 反復での値が他の 4 モデルより高く、反復を増やす余地が大きいと見る)。 *Observed:* pending. *Verdict:* pending.

Assumed, so that the claims together imply Hypothesis 1:

- temperature 1.0 での 1 回実行の平均 STE (137 件平均) の実行間変動が判定に対して十分小さいこと。件ごとの STE の標準偏差はおよそ 0.27、137 件平均の標準誤差はおよそ 0.02 で、差が 0.02 未満のときは結論が揺らぎうる (c1~c5)
- 先行研究の 20 反復の値 (同じ API、同じ Controller、同じ評価層での 1 回実行) を比較対象とし、本研究では 20 反復を再実行しないこと (c1~c5)
- 反復上限 100 はプロンプトでエージェントに伝えられ、エージェントは任意の反復で提出できる。上限を使い切らずに提出した件の割合と、文脈長の上限 (5 モデル共通の 262144 トークン) や時間切れで提出に至らなかった件の数は表で報告するが、判定には用いない。提出に至らなかった件は公式規約どおり不完全モデルの採点値で平均に含める (c1~c5)
- RIKYU の推論 API が提供する各モデルが、先行研究の時点と同じ重み・同じ serving 設定であること (c1~c5)
- aarch64 向けの libroadrunner 2.7.0 と antimony 2.14.0 が、論文環境の libroadrunner 2.8.0 と同じ軌道と評価値を与えること (c1~c5)
- 平均 STE が「反復を増やして悪化しない」を代表すること。RMS (modifier あり / なし) と NTS は同じ実行から表として報告するが、判定基準には用いない (c1~c5)

Hypothesis 2. 同じ 5 モデルは、反復上限 100 でより大きな系からなる SciGym-large 213 件を解かせたときも、いずれも平均 STE が論文 Table 1 (SciGym-small) の最良行 Gemini-2.5-Pro の 0.3212 以下になる。(Duan et al., 2025, s1.p2, s1.p5, s1.p6), (auto-res2/scigym-rikyu-open-models , AIRAS, s3.p1)

- Claim 6** kimi-k2.6 で SciGym-large 213 件を最大 100 反復で解かせたときの平均 STE は、論文 Table 1 の最良行 (Gemini-2.5-Pro) の 0.3212 以下である。(Duan et al., 2025, s1.p2, s1.p3, s1.p4, s1.p5), (auto-res2/scigym-rikyu-open-models , AIRAS, s3.p2), (h4duan, 2025, s2.p1) *Rationale:* small で最良だった kimi-k2.6 が large でも論文の最良行の水準を保てば、h2 の kimi-k2.6 の部分を担う。 *Criterion:* `kimi-k2.6-large.trajectory_smape` - 0.3212 $\leq$ 0. *Prediction:* [-0.1, 0.1] (small での 0.2100 (s3.p2) に、系が大きくなる分の悪化を見込む。先行値が無く幅を広く取る)。 *Observed:* pending. *Verdict:* pending.
- Claim 7** kimi-k3 で SciGym-large 213 件を最大 100 反復で解かせたときの平均 STE は、論文 Table 1 の最良行 (Gemini-2.5-Pro) の 0.3212 以下である。(Duan et al., 2025, s1.p2, s1.p3, s1.p4, s1.p5), (auto-res2/scigym-rikyu-open-models , AIRAS, s3.p3), (h4duan, 2025, s2.p1) *Rationale:* c6 と同じ。h2 の kimi-k3 の部分を担う。 *Criterion:* `kimi-k3-large.trajectory_smape` - 0.3212 $\leq$ 0. *Prediction:* [-0.1, 0.1] (c6 と同じ (small での値は 0.2251、s3.p3))。 *Observed:* pending. *Verdict:* pending.
- Claim 8** deepseek-v4.1-flash で SciGym-large 213 件を最大 100 反復で解かせたときの平均 STE は、論文 Table 1 の最良行 (Gemini-2.5-Pro) の 0.3212 以下である。(Duan et al., 2025, s1.p2, s1.p3, s1.p4, s1.p5), (auto-res2/scigym-rikyu-open-models , AIRAS, s3.p4), (h4duan, 2025, s2.p1) *Rationale:* c6 と同じ。h2 の deepseek-v4.1-flash の部分を担う。 *Criterion:* `deepseek-v4.1-flash-large.trajectory_smape` - 0.3212 $\leq$ 0. *Prediction:* [-0.1, 0.1] (c6 と同じ (small での値は 0.2405、s3.p4))。 *Observed:* pending. *Verdict:* pending.
- Claim 9** qwen3.8-27b で SciGym-large 213 件を最大 100 反復で解かせたときの平均 STE は、論文 Table 1 の最良行 (Gemini-2.5-Pro) の 0.3212 以下である。(Duan et al., 2025, s1.p2, s1.p3, s1.p4, s1.p5), (auto-res2/scigym-rikyu-open-models , AIRAS, s3.p5), (h4duan, 2025, s2.p1) *Rationale:* c6 と同じ。h2 の qwen3.8-27b の部分を担う。 *Criterion:* `qwen3.8-27b-large.trajectory_smape` - 0.3212 $\leq$ 0. *Prediction:* [-0.1, 0.1] (c6 と同じ (small での値は 0.2479、s3.p5))。 *Observed:* pending. *Verdict:* pending.
- Claim 10** qwen3.6-35b で SciGym-large 213 件を最大 100 反復で解かせたときの平均 STE は、論文 Table 1 の最良行 (Gemini-2.5-Pro) の 0.3212 以下である。(Duan et al., 2025, s1.p2, s1.p3, s1.p4, s1.p5), (auto-res2/scigym-rikyu-open-models , AIRAS, s3.p6), (h4duan, 2025, s2.p1) *Rationale:* c6 と同じ。h2 の qwen3.6-35b の部分を担う。small では 0.4571 と基準を上回っていたので、反復を増やしても届かない可能性が高い。 *Criterion:* `qwen3.6-35b-large.trajectory_smape` - 0.3212 $\leq$ 0. *Prediction:*

[0, 0.25] (small での 0.4571 (s3.p6) が基準を 0.14 上回っていた。反証されると予測する)。 *Observed*: pending. *Verdict*: pending.

Assumed, so that the claims together imply Hypothesis 2:

- large split には論文の公表値が無いので、論文の small での最良値を絶対水準の基準とする。難易度の差は small の表と並べて示すが、判定には用いない (c6~c10)
- 213 件平均の実行間変動が判定に対して十分小さいこと。件ごとの標準偏差を 0.27 とすれば平均の標準誤差はおおよそ 0.02 (c6~c10)
- 文脈長 (262144) や時間切れで提出に至らなかった件は不完全モデルの採点値で平均に含める。large は SBML が長く文脈超過が増えうるが、その件数を表で報告する (c6~c10)
- 評価層 scigym_large (airas-eval v0.13.0) が公式リリースの large split 213 件を sha256 で固定し、small と同じ公式 Evaluator で採点すること (c6~c10)

判定基準と予測区間の根拠. 仮説 1 (small) の各主張の反証線は「(当該モデルの 100 反復での平均 STE) - (先行研究の 20 反復での平均 STE) ≤ 0 」である。先行研究の値は同じ API、同じ Controller、同じ評価層での 1 回実行であり、本研究では 20 反復を再実行しない。予測区間は [-0.08, 0.02] (qwen3.6-35b は 20 反復での値が高く余地が大きいので [-0.15, 0.02]) とする。20 反復では大半の件が上限まで使い切っていたので改善の余地はあるが、文脈が長くなると推論が乱れることもあり、改善は小さめと見る。

仮説 2 (large) の各主張の反証線は「(当該モデルの large での平均 STE) - 0.3212 ≤ 0 」である。large には論文の公表値が無いので、論文の small での最良行 Gemini-2.5-Pro の STE (Duan et al., 2025, s1.p5) を絶対水準の基準に置く。予測区間は [-0.10, 0.10] とし、small で基準を上回っていた qwen3.6-35b だけは [0, 0.25] (反証されると予測) とする。1 件の STE の標準偏差を 0.27 程度と見積もると 137 件平均の標準誤差は約 0.02 で、差が 0.02 未満のときは結論が揺らぎうることを前提として記録する。

RMS (modifier あり / なし) と NTS、提出までの反復数、上限前に自ら提出した件数、文脈超過で提出に至らなかった件数は同じ実行から表として報告するが、判定には用いない。small と large の難易度差も表で示すにとどめ、主張にはしない。

4 方法

タスク. 各インスタンスは真の SBML (truth.xml)、反応を取り除いた不完全な SBML (partial.xml)、シミュレーション条件 (truth.sedml) からなる。エージェントは不完全な SBML を受け取り、各ターンで実験 (初期濃度の変更を指定し、真のモデルの時系列を得る)、コード実行 (numpy / pandas / scipy / libsbml と、仮説モデルを走らせる simulate 関数が使える)、提出のいずれかを markdown 形式で返す。提出は任意の時点で行え、反復数の上限はプロンプトでエージェントに伝えられる (Duan et al., 2025, s1.p3)。提出した SBML が無効な場合は追加のデバッグ反復が許され、それでも無効なら不完全 SBML のまま採点される (Duan et al., 2025, s1.p4)。

実行系. ループ、プロンプト、実験の実行はすべて公開コード (h4duan, 2025) の Controller をそのまま用いる。本研究が書くのは、(1) OpenAI 互換 API でモデルを呼ぶ LLM 実装 (公式の GPT 実装と同じく、システムプロンプトと全履歴を毎回送る)、(2) インスタンスごとに 1 プロセスで Controller を起動して並列に走らせ、終わった件を 1 件 1 書庫で保存する駆動部、(3) 各インスタンスの提出モデルと公式データを評価層の入力ファイルに書き出す部分だけである。会話が文脈長を超えて API が要求を拒んだ件は、その時点で終了し「文脈超過」として数える。提出に至らなかった件は公式規約どおり不完全 SBML の採点値で平均に含める。

指標. 採点は評価層 airas-eval のベンチマークパック scigym_small (137 件) と scigym_large (213 件) が行う。パックは公式リリースの各件 (truth / partial / sedml) を sha256 で固定し、公開コードの Evaluator (コミット 88a7b93) で提出モデルを採点して、STE (trajectory_smape)、RMS の適合率・再現率・F1 (modifier なし reaction_*, あり reaction_*_with_modifiers)、NTS の F1 (topology_f1) を件の単純平均で返す。

5 実験設計

モデル. RIKYU の推論 API が提供する open-weight モデルのうち、先行研究で 20 反復の full run が完走した 5 モデルを用いる: kimi-k2.6、kimi-k3、deepseek-v4.1-flash、qwen3.8-27b、qwen3.6-35b。いずれも思考 (thinking) を出力するモデルである。文脈長は qwen 2 種と kimi-k2.6 が 262144、deepseek-v4.1-flash が 1000000、kimi-k3 が 928000 トークンで、5 モデル共通の上限 262144 を設計の基準にする。GLM 系は先行研究で生成速度が遅く期限内に終わらなかったため除く。

データ. SciGym の公式リリース (Hugging Face h4duan/scigym-sbml) のうち、論文が評価対象とした small split 137 件 (Duan et al., 2025, s1.p2) に加え、論文では評価されていない large split 213 件を用いる (いずれも RIKYU 上のコピー)。large の真のモデルの SBML は small のおよそ 3.5 倍長い。評価層は各件の内容を公式リリースの sha256 と照合する。

反復上限. max_iterations は 100 とする。当初は 200 を検討したが、先行研究の 20 反復の会話は 1 反復あたり中央値 0.85k、90 パーセンタイル 1.3k トークン伸びており、出力用に 32768 を確保した入力の上限約 230k トークンでは、200 反復だと large で 90 パーセンタイルの件が文脈長を超える見込みだった。また 1 モデル 1 run で small か large の全件を回すと、計算機の 1 job 4 日の上限に対して 200 反復は収まらない。この 2 つの理由で small / large 共通の上限を 100 に下げた。100 でも一部の件は文脈長を超えうるので、その件数を表で報告する。

設定. eval_debug_rounds は論文本文の 3 (Duan et al., 2025, s1.p4) (公開 config の既定値は 5 (h4duan, 2025, s2.p3))、temperature は公開 config の 1.0 (h4duan, 2025, s2.p1)、摂動は初期濃度の変更のみとする。応答のトークン上限は 32768 とし、思考で使い切った応答は文脈長に収まる範囲で上限を倍にして呼び直す。本文が空で返った呼び出しは呼び直し、reasoning 側に本文が入っていればそれを用いる。各モデル、各インスタンスを 1 回ずつ実行する。1 件の試行の上限時間は 36 時間とし、上限で打ち切られた件は最大 3 回やり直す。

計算資源と環境. 実行は Seyval を通じて RIKYU (Slurm、GB200 ノード、aarch64) で行い、LLM は同じ RIKYU の推論 API を呼ぶ。GPU は使わないが、資源の単位が GPU であるため 1 GPU を要求する。1 run は 1 モデル × 1 split で、48 件を並列に走らせる。1 job の上限は 4 日で、打ち切られた run は保存済みの件の書庫から続きを実行する。環境は Dockerfile と uv.lock で固定する。aarch64 向けの wheel が無いため、libroadrunner は公式の 2.8.0 ではなく 2.7.0、antimony は 2.14.0 を用い、rrplugins と phrasedml は除外する。

段階. sanity は各 split の先頭 1 件を 2 反復で走らせて配管を確かめる。pilot は sorted した件から等間隔に 10 件を 100 反復で走らせ、1 件あたりの所要時間と文脈の伸びを測る。主張の判定は full の結果だけで行い、sanity と pilot の結果は記録に取り込まない。

run と主張の対応. small: kimi-k2.6-small → Claim 1、kimi-k3-small → Claim 2、deepseek-v4.1-flash-small → Claim 3、qwen3.8-27b-small → Claim 4、qwen3.6-35b-small → Claim 5。large: kimi-k2.6-large → Claim 6、kimi-k3-large → Claim 7、deepseek-v4.1-flash-large → Claim 8、qwen3.8-27b-large → Claim 9、qwen3.6-35b-large → Claim 10。

6 結果

本版 (2026 年 9 月 29 日 10:00 JST 時点) では完走した run が無く、主張の判定はすべて保留である。各 run の平均 STE、RMS、有効提出件数、平均反復数、早期提出件数、文脈超過件数は、run がそろい次第 small と large の表として記録から流し込み、先行研究の 20 反復の値と並べた対比表とともに改版で記入する。以下には執筆時点の実行状況と、実行中に判明した事実を記す。

執筆時点の実行状況. 10 run はいずれも実行中で、完了件数 (提出モデルの採点まで終わった件) は small が kimi-k3 129 / 137、qwen3.6-35b 124 / 137、deepseek-v4.1-flash 103 / 137、kimi-k2.6 1 / 137、qwen3.8-27b 0 / 137、large が qwen3.6-35b 170 / 213、deepseek-v4.1-flash

125 / 213, kimi-k3 108 / 213, kimi-k2.6 0 / 213, qwen3.8-27b 0 / 213 である。これらの数は run の作業ディレクトリを数えたもので、記録には入っていない。kimi-k2.6 と qwen3.8-27b の 4 run が進んでいないのは、後述する推論 API の停止による。

実行で起きたこと. 事前登録した設計からの逸脱と、実行中に判明した事実を記す。第一に、LLM が書いた解析コードや提出モデルの評価が ODE ソルバーの C ライブラリの中で止まり、公式 Controller の 3 分制限 (signal.alarm) が効かない件が多発した。事前登録では 1 試行の上限を 36 時間としていたが、この設計では止まった件が 48 並列の枠を長時間塞ぐため、実行の途中で「出力が 90 分止まった試行を打ち切って反復 0 からやり直す」判定を駆動部に加え、走っていた 10 run をすべて止めて、完了済みの件を引き継いで投げ直した。この変更は Controller、プロンプト、モデルの呼び方、採点には触れておらず、引き継いだ件は変更前と同じ条件で解かれている。執筆時点の打ち切り回数は deepseek-v4.1-flash の large で 31、small で 25、kimi-k3 の large で 18、qwen3.6-35b の large で 9 である。第二に、実行開始から約 7 時間後 (2026 年 9 月 28 日 15:40 UTC 頃) に RIKYU の推論 API が deepseek-v4.1-flash を除く全モデルで 502 または無応答になった。kimi-k3、qwen3.6-35b、deepseek-v4.1-flash は約 1 時間半で復旧したが、kimi-k2.6 と qwen3.8-27b は執筆時点 (停止から 9 時間後) でも応答がない。停止の原因は分かっていないが、10 run $\times$ 48 並列の長い文脈の要求が上流のサーバーを落とした可能性がある。当時の実験コードは 5xx を 30 分呼び直すと試行を落とし、その件の反復を最初からやり直していたため、5xx と接続断を最大 6 時間呼び直すように変え、再度 10 run を止めて完了済みの件を引き継いで投げ直した。第三に、評価入力 (参照 SBML と提出 SBML) が large では 1 run で 100 MB 近くになり、記録への取り込み上限 50 MB を超えるため、評価入力を gzip で書くように駆動部と評価層 (airas-eval 0.13.1) を変えた。第四に、文脈長 262144 トークンを超えて提出に至らなかった件が執筆時点で qwen3.6-35b の large で 18 件、kimi-k3 の large で 6 件、qwen3.6-35b の small で 5 件、deepseek-v4.1-flash の large で 4 件ある。事前登録の見込み (100 反復なら 90 パーセンタイルの件が収まる) よりも large で多く、反復ごとに積み上がる実験データの表が大きい系で文脈を圧迫している。これらの経緯は記録の notes にも残した。

7 考察

判定が出ていないので、考察は執筆時点で言えることに限る。

反復を 100 に増やすと、時間と文脈の両方が制約になる. 反復上限 20 の先行研究の run は 1 本あたり 9~20 時間で終わっていた (本研究と同じ計算機での実行記録による) が、100 反復では 1 件に 6~12 時間かかり、48 並列でも 137 件の small に丸 1 日以上を要している。さらに、C ライブラリ内で止まる件が反復数に比例して増え、止まった件をどう打ち切るかが run の所要時間を支配した。文脈超過も large で目立ち始めており、100 反復という上限は 262144 トークンの窓に対して大きな系では余裕がない。反復上限を 200 から 100 に下げた判断 (第 5 節) は、この観察と整合している。

推論 API の停止は open-weight モデル評価の再現性を左右する. 先行研究でも qwen3.6-35b の API が 1 日応答しなかったが、本研究では複数モデルが同時に落ち、一部は 9 時間以上回復していない。API が落ちると試行が落ちて反復が無駄になる設計だったため、呼び直しの上限を 6 時間に延ばした。open-weight モデルを自前の serving で評価する場合、モデルの能力とは別に、serving の安定性が結果の件数と所要時間に直接効く。

8 結論

本版は中間報告であり、仮説 1 (反復を 100 に増やしても小規模データで悪化しない) と仮説 2 (大規模データでも論文最良行の水準に達する) の判定はすべて保留である。実行の途中で、C ライブラリ内での停止に対する打ち切り規則、推論 API 停止に対する呼び直しの上限、評価入力の圧縮の 3 点を駆動部に加え、完了済みの件を引き継いで run を投げ直した。これらは Controller と採点には触れていない。run がそろい次第、記録に結果を追記して判定と考察を改版で記す。

データの利用可能性

記録は record.json にある。実験コード、環境の固定 (Dockerfile と uv.lock)、各 run の結果と provenance は同じリポジトリに含まれる。

REFERENCES

auto-res2/scigym-rikyu-open-models (AIRAS). Scigym-small における open-weight モデルの事前登録評価: Rikyu の推論 api で提供される 8 モデルは論文の gpt-4.1-mini に届くか, 2026. URL <https://github.com/auto-res2/scigym-rikyu-open-models>. commit 448f37a09a0b08100c7106ae09d7dfdb474c5372.

Haonan Duan, Stephen Zhewen Lu, Caitlin Fiona Harrigan, Nishkrit Desai, Jiarui Lu, Michał Koziarski, Leonardo Cotta, and Chris J. Maddison. Measuring scientific capabilities of language models with a systems biology dry lab. *arXiv preprint arXiv:2507.02083 (NeurIPS 2025 Datasets and Benchmarks Track)*, 2025. URL <https://arxiv.org/pdf/2507.02083>.

h4duan. h4duan/scigym, 2025. URL <https://github.com/h4duan/SciGym>. commit 88a7b93609e35b6ecb4eb343d816d6ff09256c6a.